



TIDYMODELS

The tidymodels framework is a collection of packages for modeling and machine learning using **tidyverse** principles.

Install tidymodels with:

```
install.packages("tidymodels")
```

• Introducción a Tidymodels

• Introducción a Tidymodels

- *Hadley Wickham* y *Garrett Golemund* escribieron un difundido libro denominado *R for Data Science* que explica las bases del lenguaje para realizar exploración de datos, *data wrangling* y algo de programación. Finalizan su libro con las bases del modelamiento predictivo.

• Introducción a Tidymodels


- *Hadley Wickham y Garrett Golemund* escribieron un difundido libro denominado *R for Data Science* que explica las bases del lenguaje para realizar exploración de datos, *data wrangling* y algo de programación. Finalizan su libro con las bases del modelamiento predictivo.
- Para individuos experimentados en Ciencia de datos, el texto deja la sensación de que **R** no es un buen ambiente para hacer verdadera Ciencia de datos, a pesar de la cantidad de librerías que implementan algoritmos para aplicar métodos para apredizaje supervisado y de apredizaje no supervisado.

• Introducción a Tidymodels

- *Hadley Wickham y Garrett Golemund* escribieron un difundido libro denominado *R for Data Science* que explica las bases del lenguaje para realizar exploración de datos, *data wrangling* y algo de programación. Finalizan su libro con las bases del modelamiento predictivo.
- Para individuos experimentados en Ciencia de datos, el texto deja la sensación de que **R** no es un buen ambiente para hacer verdadera Ciencia de datos, a pesar de la cantidad de librerías que implementan algoritmos para aplicar métodos para aprendizaje supervisado y de aprendizaje no supervisado.
- **RStudio** es una compañía que cuenta con cientos de programadores y se ha dedicado a crear librerías con algoritmos más rápidos, además de *crear infraestructura* para lograr que se lleve a cabo el modelamiento.

- Hadley Wickham, un prominente programador de RStudio, es quien ha participado en el desarrollo de librerías como *ggplot2*, *dplyr*, *tidyr*, *stringr* y *lubridate*, además de otras para importación de datos e ingeniería de software. Es lo que se ha denominado el *ecosistema tidyverse* en R

- Hadley Wickham, un prominente programador de RStudio, es quien ha participado en el desarrollo de librerías como *ggplot2*, *dplyr*, *tidyr*, *stringr* y *lubridate*, además de otras para importación de datos e ingeniería de software. Es lo que se ha denominado el *ecosistema tidyverse* en R
- El libro mencionado, R for Data Science, expone dicho universo, no exactamente la Ciencia de datos.



- Desde hace un par de años *Max Kuhn*, uno de los autores de *Applied Predictive Modeling*, libro básico para la Ciencia de datos en la pasada década, y uno de los desarrolladores de la librería *caret* de R, es ahora uno de los encargados de crear un *ecosistema de Ciencia de datos* consistente y ordenado, que RStudio ha denominado: *tidymodels*.

¹Existen otras, pero éstas son las básicas

- Desde hace un par de años *Max Kuhn*, uno de los autores de *Applied Predictive Modeling*, libro básico para la Ciencia de datos en la pasada década, y uno de los desarrolladores de la librería *caret* de R, es ahora uno de los encargados de crear un *ecosistema de Ciencia de datos* consistente y ordenado, que RStudio ha denominado: *tidymodels*.
- Las librerías base del ecosistema tidymodels ¹, son:

¹Existen otras, pero éstas son las básicas

- Desde hace un par de años *Max Kuhn*, uno de los autores de *Applied Predictive Modeling*, libro básico para la Ciencia de datos en la pasada década, y uno de los desarrolladores de la librería *caret* de R, es ahora uno de los encargados de crear un *ecosistema de Ciencia de datos* consistente y ordenado, que RStudio ha denominado: *tidymodels*.
- Las librerías base del ecosistema *tidymodels* ¹, son:
 - **rsample**: Prepara los datos para métodos supervisados y realiza remuestreos (bootstrapping y validación cruzada)

¹Existen otras, pero éstas son las básicas

- Desde hace un par de años *Max Kuhn*, uno de los autores de *Applied Predictive Modeling*, libro básico para la Ciencia de datos en la pasada década, y uno de los desarrolladores de la librería *caret* de R, es ahora uno de los encargados de crear un *ecosistema de Ciencia de datos* consistente y ordenado, que RStudio ha denominado: *tidymodels*.
- Las librerías base del ecosistema *tidymodels* ¹, son:
 - **rsample**: Prepara los datos para métodos supervisados y realiza remuestreos (bootstrapping y validación cruzada)
 - **recipes**: Preprocesa datos y facilita la ingeniería de selección de características (features)

¹ Existen otras, pero éstas son las básicas

- Desde hace un par de años *Max Kuhn*, uno de los autores de *Applied Predictive Modeling*, libro básico para la Ciencia de datos en la pasada década, y uno de los desarrolladores de la librería *caret* de R, es ahora uno de los encargados de crear un *ecosistema de Ciencia de datos* consistente y ordenado, que RStudio ha denominado: *tidymodels*.
- Las librerías base del ecosistema *tidymodels* ¹, son:
 - **rsample**: Prepara los datos para métodos supervisados y realiza remuestreos (bootstrapping y validación cruzada)
 - **recipes**: Preprocesa datos y facilita la ingeniería de selección de características (features)
 - **parsnip**: Apoya la definición y el ajuste de modelos

¹ Existen otras, pero éstas son las básicas

- Desde hace un par de años *Max Kuhn*, uno de los autores de *Applied Predictive Modeling*, libro básico para la Ciencia de datos en la pasada década, y uno de los desarrolladores de la librería *caret* de R, es ahora uno de los encargados de crear un *ecosistema de Ciencia de datos* consistente y ordenado, que RStudio ha denominado: *tidymodels*.
- Las librerías base del ecosistema *tidymodels* ¹, son:
 - **rsample**: Prepara los datos para métodos supervisados y realiza remuestreos (bootstrapping y validación cruzada)
 - **recipes**: Preprocesa datos y facilita la ingeniería de selección de características (features)
 - **parsnip**: Apoya la definición y el ajuste de modelos
 - **broom**: Apoya el resumen de los modelos ajustados

¹ Existen otras, pero éstas son las básicas

- Desde hace un par de años *Max Kuhn*, uno de los autores de *Applied Predictive Modeling*, libro básico para la Ciencia de datos en la pasada década, y uno de los desarrolladores de la librería *caret* de R, es ahora uno de los encargados de crear un *ecosistema de Ciencia de datos* consistente y ordenado, que RStudio ha denominado: *tidymodels*.
- Las librerías base del ecosistema *tidymodels*¹, son:
 - **rsample**: Prepara los datos para métodos supervisados y realiza remuestreos (bootstrapping y validación cruzada)
 - **recipes**: Preprocesa datos y facilita la ingeniería de selección de características (features)
 - **parsnip**: Apoya la definición y el ajuste de modelos
 - **broom**: Apoya el resumen de los modelos ajustados
 - **dials y tune**: Responsables del afinamiento o exploración (tuning) de los parámetros de los modelos

¹ Existen otras, pero éstas son las básicas

- Desde hace un par de años *Max Kuhn*, uno de los autores de *Applied Predictive Modeling*, libro básico para la Ciencia de datos en la pasada década, y uno de los desarrolladores de la librería *caret* de R, es ahora uno de los encargados de crear un *ecosistema de Ciencia de datos* consistente y ordenado, que RStudio ha denominado: *tidymodels*.
- Las librerías base del ecosistema *tidymodels* ¹, son:
 - **rsample**: Prepara los datos para métodos supervisados y realiza remuestreos (bootstrapping y validación cruzada)
 - **recipes**: Preprocesa datos y facilita la ingeniería de selección de características (features)
 - **parsnip**: Apoya la definición y el ajuste de modelos
 - **broom**: Apoya el resumen de los modelos ajustados
 - **dials y tune**: Responsables del afinamiento o exploración (tuning) de los parámetros de los modelos
 - **yardstick**: Evalúa el rendimiento de los modelos y su validación

¹ Existen otras, pero éstas son las básicas

- Desde hace un par de años *Max Kuhn*, uno de los autores de *Applied Predictive Modeling*, libro básico para la Ciencia de datos en la pasada década, y uno de los desarrolladores de la librería *caret* de R, es ahora uno de los encargados de crear un *ecosistema de Ciencia de datos* consistente y ordenado, que RStudio ha denominado: *tidymodels*.
- Las librerías base del ecosistema *tidymodels* ¹, son:
 - **rsample**: Prepara los datos para métodos supervisados y realiza remuestreos (bootstrapping y validación cruzada)
 - **recipes**: Preprocesa datos y facilita la ingeniería de selección de características (features)
 - **parsnip**: Apoya la definición y el ajuste de modelos
 - **broom**: Apoya el resumen de los modelos ajustados
 - **dials y tune**: Responsables del afinamiento o exploración (tuning) de los parámetros de los modelos
 - **yardstick**: Evalúa el rendimiento de los modelos y su validación
 - **workflows**: Organiza el flujo de modelamiento (pipeline).

¹ Existen otras, pero éstas son las básicas

- **rsample**. Tiene funciones para crear remuestras, a través de procedimientos de bootstrap y validación cruzada, de un conjunto de datos que pueden usarse para evaluar modelos o estimar la distribución de muestreo de alguna estadística

- **rsample**. Tiene funciones para crear remuestras, a través de procedimientos de bootstrap y validación cruzada, de un conjunto de datos que pueden usarse para evaluar modelos o estimar la distribución de muestreo de alguna estadística
- **recipes**. Consiste en uno o más *pasos* de manipulación y análisis de datos. Los parámetros estadísticos para los pasos pueden estimarse a partir de un conjunto de datos inicial y luego aplicarse a otros conjuntos de datos. Esta hecha de tal modo que difiere los cálculos

- **rsample**. Tiene funciones para crear remuestras, a través de procedimientos de bootstrap y validación cruzada, de un conjunto de datos que pueden usarse para evaluar modelos o estimar la distribución de muestreo de alguna estadística
- **recipes**. Consiste en uno o más *pasos* de manipulación y análisis de datos. Los parámetros estadísticos para los pasos pueden estimarse a partir de un conjunto de datos inicial y luego aplicarse a otros conjuntos de datos. Esta hecha de tal modo que difiere los cálculos
- **parsnip**. Una interfaz para modelar que permite, mediante un llamado de parámetros unificado, probar una gran gama de modelos sin atorarse en las minucias sintácticas del subyacente paquete. Es el sucesor de la librería *caret*. También esta hecha de tal modo que difiere los cálculos. Tiene un conjunto de librerías opcionales asociadas

- **broom**. Convierte los objetos de análisis estadístico (fits) de R y los organiza en tres tipos de información mediante tres comandos genéricos: `tidy()`, que resume los hallazgos estadísticos de un modelo, como los coeficientes de una regresión; `augment()`, que agrega columnas a los datos originales con las predicciones, residuos y asignaciones de cluster; y `glance()`, que proporciona un resumen de estadísticas a nivel del modelo

- **broom**. Convierte los objetos de análisis estadístico (fits) de R y los organiza en tres tipos de información mediante tres comandos genéricos: `tidy()`, que resume los hallazgos estadísticos de un modelo, como los coeficientes de una regresión; `augment()`, que agrega columnas a los datos originales con las predicciones, residuos y asignaciones de cluster; y `glance()`, que proporciona un resumen de estadísticas a nivel del modelo
- **dials**. Contiene herramientas para crear y administrar valores de parámetros y está diseñado para integrarse bien con el paquete `parsnip`

- **broom**. Convierte los objetos de análisis estadístico (fits) de R y los organiza en tres tipos de información mediante tres comandos genéricos: `tidy()`, que resume los hallazgos estadísticos de un modelo, como los coeficientes de una regresión; `augment()`, que agrega columnas a los datos originales con las predicciones, residuos y asignaciones de cluster; y `glance()`, que proporciona un resumen de estadísticas a nivel del modelo
- **dials**. Contiene herramientas para crear y administrar valores de parámetros y está diseñado para integrarse bien con el paquete `parsnip`
- **tune**. Contiene funciones y clases que se utilizan junto con otros paquetes *tidymodels* para encontrar valores razonables de los parámetros, por ejemplo, de regularización, métodos de procesamiento previo y pasos de procesamiento posterior

- **broom**. Convierte los objetos de análisis estadístico (fits) de R y los organiza en tres tipos de información mediante tres comandos genéricos: `tidy()`, que resume los hallazgos estadísticos de un modelo, como los coeficientes de una regresión; `augment()`, que agrega columnas a los datos originales con las predicciones, residuos y asignaciones de cluster; y `glance()`, que proporciona un resumen de estadísticas a nivel del modelo
- **dials**. Contiene herramientas para crear y administrar valores de parámetros y está diseñado para integrarse bien con el paquete `parsnip`
- **tune**. Contiene funciones y clases que se utilizan junto con otros paquetes *tidymodels* para encontrar valores razonables de los parámetros, por ejemplo, de regularización, métodos de procesamiento previo y pasos de procesamiento posterior
- **yardstick**. Herramienta *tidy* para cuantificar qué tan bien se ajusta el modelo a un conjunto de datos: matrices de confusión, resúmenes de curvas de probabilidad y métricas,

- **workflow**. Es el componente fundamental que permite conectar el preprocesamiento de datos y el modelado predictivo. Permite ajustar y realizar predicciones con un simple llamado fit/predict, sobre un objeto único que guarda todo el preprocesamiento realizado

Pre-Process → Train → Validate



tidymodels: Adventures in Rewriting a Modeling Pipeline

