

- **Machine Learning en Seguros**

- Machine Learning en Seguros
- Módulo IV Tema 1

- **Machine Learning en Seguros**
- **Módulo IV Tema 1**
- **Modelos Lineales Generalizados (GLM)**

- Machine Learning en Seguros
- Módulo IV Tema 1
- Modelos Lineales Generalizados (GLM)
- Introducción

- Machine Learning en Seguros
- Módulo IV Tema 1
- Modelos Lineales Generalizados (GLM)
- Introducción
- Los modelos lineales son modelos estadísticos que sirven para cuantificar el impacto o influencia que tienen las llamadas *variables explicativas* (características de los sujetos o entidades que conforman el modelo) en la llamada *variable de respuesta*

- Machine Learning en Seguros
- Módulo IV Tema 1
- Modelos Lineales Generalizados (GLM)
- Introducción
- Los modelos lineales son modelos estadísticos que sirven para cuantificar el impacto o influencia que tienen las llamadas *variables explicativas* (características de los sujetos o entidades que conforman el modelo) en la llamada *variable de respuesta*
- El más sencillo de estos modelos es el de regresión lineal simple, cuya extensión natural es el modelo de regresión lineal múltiple. Este es, probablemente, el modelo lineal más conocido en la literatura estadística

- **Machine Learning en Seguros**

- **Módulo IV Tema 1**

- **Modelos Lineales Generalizados (GLM)**

- **Introducción**

- Los modelos lineales son modelos estadísticos que sirven para cuantificar el impacto o influencia que tienen las llamadas *variables explicativas* (características de los sujetos o entidades que conforman el modelo) en la llamada *variable de respuesta*
- El más sencillo de estos modelos es el de regresión lineal simple, cuya extensión natural es el modelo de regresión lineal múltiple. Este es, probablemente, el modelo lineal más conocido en la literatura estadística
- La característica esencial de este modelo es que la variable de respuesta se asume con distribución continua y su componente aleatorio se supone con distribución normal, distribución que hereda la variable de respuesta.

- En la modelación estadística muchas veces se tienen variables de respuesta que no son continuas, por ejemplo la condición de enfermo y no enfermo de un paciente; la preferencia electoral de un sujeto en un marco de tres partidos políticos en competencia; el número de reclamaciones en una póliza de seguros, propiamente la reclamación en una póliza de seguros, etc.

- En la modelación estadística muchas veces se tienen variables de respuesta que no son continuas, por ejemplo la condición de enfermo y no enfermo de un paciente; la preferencia electoral de un sujeto en un marco de tres partidos políticos en competencia; el número de reclamaciones en una póliza de seguros, propiamente la reclamación en una póliza de seguros, etc.
- Para este tipo de respuestas, el modelo de regresión lineal usual no es, de ninguna manera, una opción adecuada, por lo que es necesario modificar o ampliar este modelo para contemplar este tipo de respuestas

- En la modelación estadística muchas veces se tienen variables de respuesta que no son continuas, por ejemplo la condición de enfermo y no enfermo de un paciente; la preferencia electoral de un sujeto en un marco de tres partidos políticos en competencia; el número de reclamaciones en una póliza de seguros, propiamente la reclamación en una póliza de seguros, etc.
- Para este tipo de respuestas, el modelo de regresión lineal usual no es, de ninguna manera, una opción adecuada, por lo que es necesario modificar o ampliar este modelo para contemplar este tipo de respuestas
- De esta necesidad surgen los llamados *Modelos lineales Generalizados (GLM)* en los que existen diversas estructuras de su componente aleatorio, que se adecuan de mejor manera a las características de escala de medición de sus respuestas. Estos modelos están caracterizados por tres componentes

- Componentes de los GLM

- Componentes de los GLM

- Componente aleatorio (parte aleatoria): $\mu = \mathbf{E}(y|\mathbf{X}) = y$

- Componentes de los GLM

- Componente aleatorio (parte aleatoria): $\mu = \mathbf{E}(y|\mathbf{X}) = y$
- Un predictor lineal (parte sistemática): $\eta = \mathbf{X}'\beta$

- Componentes de los GLM

- Componente aleatorio (parte aleatoria): $\mu = \mathbf{E}(y|\mathbf{X}) = y$
- Un predictor lineal (parte sistemática): $\eta = \mathbf{X}'\beta$
- Una función liga: $g(\mu)$

- Componentes de los GLM

- **Componente aleatorio (parte aleatoria):** $\mu = \mathbf{E}(y|\mathbf{X}) = y$
- **Un predictor lineal (parte sistemática):** $\eta = \mathbf{X}'\beta$
- **Una función liga:** $g(\mu)$
- El componente aleatorio tiene que ver con la distribución que se le asocia a la respuesta (la parte aleatoria) del modelo, misma que es sugerida por la escala de medición de esta respuesta. En los *GLM*, esta distribución debe ser un miembro de la *familia exponencial*

- Componentes de los GLM

- Componente aleatorio (parte aleatoria): $\mu = \mathbf{E}(y|\mathbf{X}) = y$
- Un predictor lineal (parte sistemática): $\eta = \mathbf{X}'\beta$
- Una función liga: $g(\mu)$
- El componente aleatorio tiene que ver con la distribución que se le asocia a la respuesta (la parte aleatoria) del modelo, misma que es sugerida por la escala de medición de esta respuesta. En los *GLM*, esta distribución debe ser un miembro de la *familia exponencial*
- El predictor lineal lo constituye la parte determinística del modelo, es decir, los datos y los parámetros

- Componentes de los GLM

- **Componente aleatorio (parte aleatoria):** $\mu = \mathbf{E}(y|\mathbf{X}) = y$
- **Un predictor lineal (parte sistemática):** $\eta = \mathbf{X}'\beta$
- **Una función liga:** $g(\mu)$
- El componente aleatorio tiene que ver con la distribución que se le asocia a la respuesta (la parte aleatoria) del modelo, misma que es sugerida por la escala de medición de esta respuesta. En los *GLM*, esta distribución debe ser un miembro de la *familia exponencial*
- El predictor lineal lo constituye la parte determinística del modelo, es decir, los datos y los parámetros
- Finalmente, la liga es una función que liga o asocia una transformación de la variable de respuesta con el predictor lineal. La estructura de este modelo es

- Estructura del GLM

- Estructura del GLM



$$\begin{aligned}g(\mu) &= \mathbf{X}'\beta = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p \quad \text{ó} \\ \mu &= \mathbf{g}^{-1}(\mathbf{X}'\beta)\end{aligned}$$

- Estructura del GLM



$$\begin{aligned}g(\mu) &= \mathbf{X}'\beta = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p \quad \text{ó} \\ \mu &= \mathbf{g}^{-1}(\mathbf{X}'\beta)\end{aligned}$$

- Los miembros de la familia exponencial que determinan los principales *GLM* son

• Modelos de la Familia Exponencial

Función liga	$g(\mu)$	Liga canónica para
Idéntica	μ	Normal
log	$\ln(\mu)$	Poisson
Potencia	μ^p	Gamma (p=-1) Gaussiana Inversa (p=-2)
Logit	$\ln\left(\frac{\mu}{1-\mu}\right)$	Binomial

- Ya que la escala de la variable de respuesta determina el modelo lineal generalizado que deba de ajustarse, observamos que

- Ya que la escala de la variable de respuesta determina el modelo lineal generalizado que deba de ajustarse, observamos que
 - El modelo de regresión lineal estándar es un *GLM* con liga idéntica. Su respuesta es una variable continua con rango en $\mathbb{R}$

- Ya que la escala de la variable de respuesta determina el modelo lineal generalizado que deba de ajustarse, observamos que
 - El modelo de regresión lineal estándar es un *GLM* con liga idéntica. Su respuesta es una variable continua con rango en $\mathbb{R}$
 - Si la respuesta es una variable de conteo, entonces el *GLM* correspondiente es el *modelo de regresión Poisson*

- Ya que la escala de la variable de respuesta determina el modelo lineal generalizado que deba de ajustarse, observamos que
 - El modelo de regresión lineal estándar es un *GLM* con liga idéntica. Su respuesta es una variable continua con rango en $\mathbb{R}$
 - Si la respuesta es una variable de conteo, entonces el *GLM* correspondiente es el *modelo de regresión Poisson*
 - Si la variable de respuesta es continua y positiva, los probables *GLM* son la regresión *Gamma* o la regresión *Gaussiana Inversa*

- Ya que la escala de la variable de respuesta determina el modelo lineal generalizado que deba de ajustarse, observamos que
 - El modelo de regresión lineal estándar es un *GLM* con liga idéntica. Su respuesta es una variable continua con rango en $\mathbb{R}$
 - Si la respuesta es una variable de conteo, entonces el *GLM* correspondiente es el *modelo de regresión Poisson*
 - Si la variable de respuesta es continua y positiva, los probables *GLM* son la regresión *Gamma* o la regresión *Gaussiana Inversa*
 - Si la variable de respuesta tiene sólo dos categorías, el *GLM* correspondiente es el *modelo de regresión logística o modelo logit*. La liga de este modelo es el logaritmo del momio de respuesta, y recibe el nombre de *logit*

- La familia exponencial

- **La familia exponencial**
- La familia de densidades de probabilidad más importante en estadística es la llamada *familia exponencial*. Cuya definición es

- **La familia exponencial**
- La familia de densidades de probabilidad más importante en estadística es la llamada *familia exponencial*. Cuya definición es
- *Familia exponencial*. Sean $y_1, \dots, y_n$ variables aleatorias independientes con función de densidad o de probabilidad, que puede escribirse como

- **La familia exponencial**

- La familia de densidades de probabilidad más importante en estadística es la llamada *familia exponencial*. Cuya definición es
- *Familia exponencial*. Sean $y_1, \dots, y_n$ variables aleatorias independientes con función de densidad o de probabilidad, que puede escribirse como



$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi) \right\}$$

- **La familia exponencial**

- La familia de densidades de probabilidad más importante en estadística es la llamada *familia exponencial*. Cuya definición es
- *Familia exponencial*. Sean $y_1, \dots, y_n$ variables aleatorias independientes con función de densidad o de probabilidad, que puede escribirse como

●

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi) \right\}$$

- Con θ_i el *parámetro canónico* y

- **La familia exponencial**

- La familia de densidades de probabilidad más importante en estadística es la llamada *familia exponencial*. Cuya definición es
- *Familia exponencial*. Sean $y_1, \dots, y_n$ variables aleatorias independientes con función de densidad o de probabilidad, que puede escribirse como

●

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi) \right\}$$

- Con θ_i el *parámetro canónico* y
- ϕ parámetro de escala o dispersión

- **La familia exponencial**

- La familia de densidades de probabilidad más importante en estadística es la llamada *familia exponencial*. Cuya definición es
- *Familia exponencial*. Sean $y_1, \dots, y_n$ variables aleatorias independientes con función de densidad o de probabilidad, que puede escribirse como

●

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi) \right\}$$

- Con θ_i el *parámetro canónico* y
- ϕ parámetro de escala o dispersión
- $a_i(\cdot)$, $b(\cdot)$ y $c(\cdot)$ funciones específicas para cada miembro de esta familia

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos
 - **Normal**

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos
 - **Normal**
 - Distribución: $N(\mu, \sigma^2)$

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos
 - **Normal**
 - Distribución: $N(\mu, \sigma^2)$
 - $\mathbb{E}(y) = \mu$

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos
 - **Normal**
 - Distribución: $N(\mu, \sigma^2)$
 - $\mathbb{E}(y) = \mu$
 - *Liga*: $g(\mu) = \mu$ (*identidad*)

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos
 - **Normal**
 - Distribución: $N(\mu, \sigma^2)$
 - $\mathbb{E}(y) = \mu$
 - *Liga*: $g(\mu) = \mu$ (*identidad*)
 - **Poisson(λ)**

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos
 - **Normal**
 - Distribución: $N(\mu, \sigma^2)$
 - $\mathbb{E}(y) = \mu$
 - *Liga*: $g(\mu) = \mu$ (*identidad*)
 - **Poisson(λ)**
 - $\mathbb{E}(y) = \lambda$

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos
 - **Normal**
 - Distribución: $N(\mu, \sigma^2)$
 - $\mathbb{E}(y) = \mu$
 - *Liga*: $g(\mu) = \mu$ (*identidad*)
 - **Poisson(λ)**
 - $\mathbb{E}(y) = \lambda$
 - *Liga*: $g(\lambda) = \log(\lambda)$

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos
 - **Normal**
 - Distribución: $N(\mu, \sigma^2)$
 - $\mathbb{E}(y) = \mu$
 - *Liga*: $g(\mu) = \mu$ (*identidad*)
 - **Poisson(λ)**
 - $\mathbb{E}(y) = \lambda$
 - *Liga*: $g(\lambda) = \log(\lambda)$
 - **Binomial(n, p)**

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos
 - **Normal**
 - Distribución: $N(\mu, \sigma^2)$
 - $\mathbb{E}(y) = \mu$
 - *Liga*: $g(\mu) = \mu$ (*identidad*)
 - **Poisson(λ)**
 - $\mathbb{E}(y) = \lambda$
 - *Liga*: $g(\lambda) = \log(\lambda)$
 - **Binomial(n, p)**
 - $\mathbb{E}(y) = n\pi$

- Si ϕ es conocido, este es un modelo de la familia exponencial lineal
- Si ϕ es desconocido, es un modelo de dispersión exponencial
- Para algunos de los modelos que especificamos en la tabla anterior tenemos

- **Normal**

- Distribución: $N(\mu, \sigma^2)$
- $\mathbb{E}(y) = \mu$
- *Liga*: $g(\mu) = \mu$ (*identidad*)

- **Poisson(λ)**

- $\mathbb{E}(y) = \lambda$
- *Liga*: $g(\lambda) = \log(\lambda)$

- **Binomial(n, p)**

- $\mathbb{E}(y) = n\pi$
- *Liga*: $g(\pi) = \ln\left(\frac{\pi}{1-\pi}\right)$ (*Logit*)

- Estimación y pruebas de hipótesis

- **Estimación y pruebas de hipótesis**
- La estimación de los parámetros que determinan cada modelo: el vector de parámetros asociados a las covariables, β , y el parámetro de escala o dispersión, ϕ , se estiman por máxima verosimilitud.

- **Estimación y pruebas de hipótesis**
- La estimación de los parámetros que determinan cada modelo: el vector de parámetros asociados a las covariables, β , y el parámetro de escala o dispersión, ϕ , se estiman por máxima verosimilitud.
- Los estimadores de sus varianzas se calculan por medio de la inversa de la llamada *Matriz de Información Observada de Fisher*. Por esta razón las inferencias para este modelo son *inferencias asintóticas* (excepto para el modelo estándar de regresión lineal)

- **Estimación y pruebas de hipótesis**
- La estimación de los parámetros que determinan cada modelo: el vector de parámetros asociados a las covariables, β , y el parámetro de escala o dispersión, ϕ , se estiman por máxima verosimilitud.
- Los estimadores de sus varianzas se calculan por medio de la inversa de la llamada *Matriz de Información Observada de Fisher*. Por esta razón las inferencias para este modelo son *inferencias asintóticas* (excepto para el modelo estándar de regresión lineal)
- La prueba de hipótesis más importante es sobre el modelo global

$$\mathbf{H}_0 : \beta = \mathbf{0}, \Rightarrow \beta_1 = \beta_2 = \dots = \beta_p = 0 \text{ vs.}$$

$$\mathbf{H}_a : \beta_i \neq 0 \text{ p.a. } i = 1, 2, \dots, p$$

- Si en un modelo concreto no rechazamos la hipótesis nula (H_0), implicaría que ninguna de nuestras covariables es importante para explicar o predecir la respuesta, lo que llevaría a desechar el modelo

- Si en un modelo concreto no rechazamos la hipótesis nula (H_0), implicaría que ninguna de nuestras covariables es importante para explicar o predecir la respuesta, lo que llevaría a desechar el modelo
- Si los modelos son propuestos por un sujeto que conoce su área de aplicación, generalmente esta hipótesis se rechaza “en favor de la hipótesis alternativa”

- Si en un modelo concreto no rechazamos la hipótesis nula (H_0), implicaría que ninguna de nuestras covariables es importante para explicar o predecir la respuesta, lo que llevaría a desechar el modelo
- Si los modelos son propuestos por un sujeto que conoce su área de aplicación, generalmente esta hipótesis se rechaza “en favor de la hipótesis alternativa”
- Entonces, como se enuncia en esta última hipótesis, lo único que sabríamos es que *al menos una covariable es importante para explicar la respuesta, y;* pero esta hipótesis no determina *cuál(es) ni cuántas*

- Si en un modelo concreto no rechazamos la hipótesis nula (H_0), implicaría que ninguna de nuestras covariables es importante para explicar o predecir la respuesta, lo que llevaría a desechar el modelo
- Si los modelos son propuestos por un sujeto que conoce su área de aplicación, generalmente esta hipótesis se rechaza “en favor de la hipótesis alternativa”
- Entonces, como se enuncia en esta última hipótesis, lo único que sabríamos es que *al menos una covariable es importante para explicar la respuesta, y;* pero esta hipótesis no determina *cuál(es) ni cuántas*
- Por lo que es necesario realizar pruebas individuales sobre cada parámetro (equivalentemente cada covariable) en el modelo. Las pruebas son del tipo

•

$$\mathbf{H}_0 : \beta_i = 0 \quad vs. \quad \mathbf{H}_a : \beta_i \neq 0 \quad i = 1, 2, \dots, p$$



$$\mathbf{H}_0 : \beta_i = 0 \quad vs. \quad \mathbf{H}_a : \beta_i \neq 0 \quad i = 1, 2, \dots, p$$

- El estadístico asociado para realizar esta prueba es una *t de Student*. En concreto se hace con la estadística



$$\mathbf{H}_0 : \beta_i = 0 \quad vs. \quad \mathbf{H}_a : \beta_i \neq 0 \quad i = 1, 2, \dots, p$$

- El estadístico asociado para realizar esta prueba es una *t de Student*. En concreto se hace con la estadística



$$\frac{\hat{\beta}_i}{\sqrt{\text{var}(\hat{\beta}_i)}} \stackrel{a}{\sim} t_{(n-p)}$$



$$\mathbf{H}_0 : \beta_i = 0 \quad vs. \quad \mathbf{H}_a : \beta_i \neq 0 \quad i = 1, 2, \dots, p$$

- El estadístico asociado para realizar esta prueba es una *t de Student*. En concreto se hace con la estadística



$$\frac{\hat{\beta}_i}{\sqrt{\text{var}(\hat{\beta}_i)}} \stackrel{a}{\sim} t_{(n-p)}$$

- En el caso del modelo de regresión lineal, y dada la normalidad de su componente aleatorio, esta estadística es



$$\mathbf{H}_0 : \beta_i = 0 \quad \text{vs.} \quad \mathbf{H}_a : \beta_i \neq 0 \quad i = 1, 2, \dots, p$$

- El estadístico asociado para realizar esta prueba es una *t de Student*. En concreto se hace con la estadística



$$\frac{\hat{\beta}_i}{\sqrt{\text{var}(\hat{\beta}_i)}} \stackrel{a}{\sim} t_{(n-p)}$$

- En el caso del modelo de regresión lineal, y dada la normalidad de su componente aleatorio, esta estadística es



$$\frac{\hat{\beta}_i}{\sqrt{\text{var}(\hat{\beta}_i)}} \sim t_{(n-p)}, \quad \text{o bien}$$

$$\frac{\hat{\beta}_i^2}{\text{var}(\hat{\beta}_i)} \sim \chi_{(1)}^2$$

- Como habíamos dicho, para este modelo las inferencias son *exactas*

- Como habíamos dicho, para este modelo las inferencias son *exactas*
- **La devianza**

- Como habíamos dicho, para este modelo las inferencias son *exactas*
- **La devianza**
- Una forma de determinar el ajuste del modelo construido es comparándolo contra el modelo que produce el mejor ajuste posible. En estos modelos, el mejor ajuste se logra cuando el modelo tiene tantos parámetros como observaciones y se le conoce como *modelo saturado*.

- Como habíamos dicho, para este modelo las inferencias son *exactas*
- **La devianza**
- Una forma de determinar el ajuste del modelo construido es comparándolo contra el modelo que produce el mejor ajuste posible. En estos modelos, el mejor ajuste se logra cuando el modelo tiene tantos parámetros como observaciones y se le conoce como *modelo saturado*.
- Este modelo lo que hace es reproducir los valores observados, por lo que su ajuste es *perfecto*. Si denotamos por $\tilde{\ell}(\beta)$ el valor de la *log-verosimilitud* del modelo saturado y por $\hat{\ell}(\beta)$ el correspondiente valor del modelo propuesto, se define la *devianza* (algunas veces llamada devianza residual) a la cantidad

- Como habíamos dicho, para este modelo las inferencias son *exactas*
- **La devianza**
- Una forma de determinar el ajuste del modelo construido es comparándolo contra el modelo que produce el mejor ajuste posible. En estos modelos, el mejor ajuste se logra cuando el modelo tiene tantos parámetros como observaciones y se le conoce como *modelo saturado*.
- Este modelo lo que hace es reproducir los valores observados, por lo que su ajuste es *perfecto*. Si denotamos por $\tilde{\ell}(\beta)$ el valor de la *log-verosimilitud* del modelo saturado y por $\hat{\ell}(\beta)$ el correspondiente valor del modelo propuesto, se define la *devianza* (algunas veces llamada devianza residual) a la cantidad

$$D = 2 \left[\tilde{\ell}(\beta) - \hat{\ell}(\beta) \right]$$

- Que puede verse como una medida de distancia entre el modelo propuesto y el saturado

- Que puede verse como una medida de distancia entre el modelo propuesto y el saturado
- Cuando el modelo propuesto provee un buen ajuste, se espera que $\widehat{\ell}(\beta)$ esté cercana a $\widetilde{\ell}(\beta)$. Es claro que ya que esta última cantidad es el supremo de todas las log-verosimilitudes posibles, $\widehat{\ell}(\beta)$ no puede ser mayor que ella. Un valor “grande” de esta devianza indica un pobre ajuste del modelo propuesto

- Que puede verse como una medida de distancia entre el modelo propuesto y el saturado
- Cuando el modelo propuesto provee un buen ajuste, se espera que $\widehat{\ell}(\beta)$ esté cercana a $\widetilde{\ell}(\beta)$. Es claro que ya que esta última cantidad es el supremo de todas las log-verosimilitudes posibles, $\widehat{\ell}(\beta)$ no puede ser mayor que ella. Un valor “grande” de esta devianza indica un pobre ajuste del modelo propuesto
- Suponiendo que el modelo es correcto y n es grande, la distribución asintótica de esta devianza es una Ji-cuadrada. En concreto

- Que puede verse como una medida de distancia entre el modelo propuesto y el saturado
- Cuando el modelo propuesto provee un buen ajuste, se espera que $\widehat{\ell}(\beta)$ esté cercana a $\widetilde{\ell}(\beta)$. Es claro que ya que esta última cantidad es el supremo de todas las log-verosimilitudes posibles, $\widehat{\ell}(\beta)$ no puede ser mayor que ella. Un valor “grande” de esta devianza indica un pobre ajuste del modelo propuesto
- Suponiendo que el modelo es correcto y n es grande, la distribución asintótica de esta devianza es una Ji-cuadrada. En concreto

$$D \stackrel{a}{\sim} \chi^2_{(n-p)}$$

- Que puede verse como una medida de distancia entre el modelo propuesto y el saturado
- Cuando el modelo propuesto provee un buen ajuste, se espera que $\widehat{\ell}(\beta)$ esté cercana a $\widetilde{\ell}(\beta)$. Es claro que ya que esta última cantidad es el supremo de todas las log-verosimilitudes posibles, $\widehat{\ell}(\beta)$ no puede ser mayor que ella. Un valor “grande” de esta devianza indica un pobre ajuste del modelo propuesto
- Suponiendo que el modelo es correcto y n es grande, la distribución asintótica de esta devianza es una Ji-cuadrada. En concreto

$$D \stackrel{a}{\sim} \chi^2_{(n-p)}$$

- Por lo que el valor esperado de esta devianza es $n-p$, y generalmente hay que examinar el valor de la devianza dividida entre sus grados de libertad. Un valor mucho mayor que *uno* indica un pobre ajuste de nuestro modelo

- En los modelos lineales generalizados esta devianza es

- En los modelos lineales generalizados esta devianza es
-

$$\mathbf{D} = 2\phi \left[\tilde{\ell}(\beta) - \hat{\ell}(\beta) \right]$$

- En los modelos lineales generalizados esta devianza es
-

$$\mathbf{D} = 2\phi \left[\tilde{\ell}(\beta) - \hat{\ell}(\beta) \right]$$

- **Comparación de modelos**

- En los modelos lineales generalizados esta devianza es



$$\mathbf{D} = 2\phi \left[\tilde{\ell}(\beta) - \hat{\ell}(\beta) \right]$$

- **Comparación de modelos**
- En la modelación estadística estándar, por lo general se tienen varios modelos que ajustan de forma adecuada a nuestra información, por lo tanto, es necesario tener una forma para compararlos y elegir el mejor entre ellos. Para hacer esta comparación es necesario que los modelos estén *anidados*, i.e., que uno de ellos sea un submodelo del otro

- En los modelos lineales generalizados esta devianza es



$$\mathbf{D} = 2\phi \left[\tilde{\ell}(\beta) - \hat{\ell}(\beta) \right]$$

- **Comparación de modelos**

- En la modelación estadística estándar, por lo general se tienen varios modelos que ajustan de forma adecuada a nuestra información, por lo tanto, es necesario tener una forma para compararlos y elegir el mejor entre ellos. Para hacer esta comparación es necesario que los modelos estén *anidados*, i.e., que uno de ellos sea un submodelo del otro
- Supongamos que tenemos dos modelos $\mathbf{M}_0$ y $\mathbf{M}_1$ con total de parámetros p_0 y p_1 , respectivamente y $p_1 > p_0$ (lo que implica que $\mathbf{M}_0$ está anidado en $\mathbf{M}_1$). Entonces, la manera de comparar estos modelos es

- En los modelos lineales generalizados esta devianza es



$$\mathbf{D} = 2\phi \left[\tilde{\ell}(\beta) - \hat{\ell}(\beta) \right]$$

- **Comparación de modelos**

- En la modelación estadística estándar, por lo general se tienen varios modelos que ajustan de forma adecuada a nuestra información, por lo tanto, es necesario tener una forma para compararlos y elegir el mejor entre ellos. Para hacer esta comparación es necesario que los modelos estén *anidados*, i.e., que uno de ellos sea un submodelo del otro
- Supongamos que tenemos dos modelos $\mathbf{M}_0$ y $\mathbf{M}_1$ con total de parámetros p_0 y p_1 , respectivamente y $p_1 > p_0$ (lo que implica que $\mathbf{M}_0$ está anidado en $\mathbf{M}_1$). Entonces, la manera de comparar estos modelos es



$$2\phi [\ell(\mathbf{M}_1) - \ell(\mathbf{M}_0)] \stackrel{a}{\sim} \chi^2_{(p_1 - p_0)}$$

- Con $\ell(\mathbf{M}_1)$ y $\ell(\mathbf{M}_0)$ las respectivas log-verosimilitudes de los correspondientes modelos

- Con $\ell(\mathbf{M}_1)$ y $\ell(\mathbf{M}_0)$ las respectivas log-verosimilitudes de los correspondientes modelos
- Si esta diferencia es *estadísticamente significativa*, podemos afirmar que las variables que tiene $\mathbf{M}_1$ pero que no están en $\mathbf{M}_0$ sirven para mejorar el ajuste del modelo. Por el contrario, si esta diferencia *no es estadísticamente significativa*, entonces querrá decir que el ajuste de ambos modelos es similar, por lo tanto, atendiendo al *principio de parsimonia*, preferimos el que tiene menos parámetros, en este caso, $\mathbf{M}_0$

- GLM: Bondad de ajuste

- **GLM: Bondad de ajuste**

- Aunque la comparación de modelos a través de sus devianzas, nos puede auxiliar en elegir aquel que mejor ajuste a nuestros datos, esto no implica que *el modelo elegido ajuste realmente*. Simplemente enuncia que, dentro de los modelos comparados, éste es el mejor. De hecho, podría ser “el menos peor”. Por lo tanto, requerimos algunas estadísticas que den cuenta de esta calidad de ajuste del modelo respecto a nuestros datos

- **GLM: Bondad de ajuste**
- Aunque la comparación de modelos a través de sus devianzas, nos puede auxiliar en elegir aquel que mejor ajuste a nuestros datos, esto no implica que *el modelo elegido ajuste realmente*. Simplemente enuncia que, dentro de los modelos comparados, éste es el mejor. De hecho, podría ser “el menos peor”. Por lo tanto, requerimos algunas estadísticas que den cuenta de esta calidad de ajuste del modelo respecto a nuestros datos
- **GLM: Residuos**

- **GLM: Bondad de ajuste**

- Aunque la comparación de modelos a través de sus devianzas, nos puede auxiliar en elegir aquel que mejor ajuste a nuestros datos, esto no implica que *el modelo elegido ajuste realmente*. Simplemente enuncia que, dentro de los modelos comparados, éste es el mejor. De hecho, podría ser “el menos peor”. Por lo tanto, requerimos algunas estadísticas que den cuenta de esta calidad de ajuste del modelo respecto a nuestros datos

- **GLM: Residuos**

- En los cursos estándar de regresión lineal, se definen muchas herramientas para comparar modelos, comprobar qué tan bien predicen, evaluar el valor de predictores individuales y elegir entre diferentes formas funcionales. Algunas de esas herramientas seguirán siendo útiles en este nuevo enfoque de GLM, pero será necesario introducir algunas otras propias para este tipo de modelos

- Sabemos que una de las herramientas más importantes para evaluar el ajuste del modelo, lo constituyen sus *residuos*. En los GLM tenemos, en general, dos tipos de residuos. A saber: *los residuos de Pearson y los residuos de devianza*

- Sabemos que una de las herramientas más importantes para evaluar el ajuste del modelo, lo constituyen sus *residuos*. En los GLM tenemos, en general, dos tipos de residuos. A saber: *los residuos de Pearson y los residuos de devianza*
- **Residuos de Pearson**. El residuo de Pearson es la estandarización del residuo de la respuesta, y_i , mediante la desviación estándar de la misma implicada por el modelo

- Sabemos que una de las herramientas más importantes para evaluar el ajuste del modelo, lo constituyen sus *residuos*. En los GLM tenemos, en general, dos tipos de residuos. A saber: *los residuos de Pearson* y *los residuos de devianza*
- **Residuos de Pearson**. El residuo de Pearson es la estandarización del residuo de la respuesta, y_i , mediante la desviación estándar de la misma implicada por el modelo

$$r_{pi} = \frac{y_i - \hat{\mu}_i}{\sqrt{\mathbb{V}(\hat{\mu}_i)}}$$

- Sabemos que una de las herramientas más importantes para evaluar el ajuste del modelo, lo constituyen sus *residuos*. En los GLM tenemos, en general, dos tipos de residuos. A saber: *los residuos de Pearson y los residuos de devianza*
- **Residuos de Pearson**. El residuo de Pearson es la estandarización del residuo de la respuesta, y_i , mediante la desviación estándar de la misma implicada por el modelo

$$r_{pi} = \frac{y_i - \hat{\mu}_i}{\sqrt{\mathbb{V}(\hat{\mu}_i)}}$$

- **Residuos estandarizados de Pearson**. El residuo estandarizado de Pearson se ajusta teniendo en cuenta *la palanca* (h_{ii} , la diagonal de la *matriz sobrero* del GLM) y el parámetro de dispersión $\hat{\phi}$

- Sabemos que una de las herramientas más importantes para evaluar el ajuste del modelo, lo constituyen sus *residuos*. En los GLM tenemos, en general, dos tipos de residuos. A saber: *los residuos de Pearson y los residuos de devianza*
- **Residuos de Pearson**. El residuo de Pearson es la estandarización del residuo de la respuesta, y_i , mediante la desviación estándar de la misma implicada por el modelo

$$r_{pi} = \frac{y_i - \hat{\mu}_i}{\sqrt{\mathbb{V}(\hat{\mu}_i)}}$$

- **Residuos estandarizados de Pearson**. El residuo estandarizado de Pearson se ajusta teniendo en cuenta la *palanca* (h_{ii} , la diagonal de la *matriz sobrero* del GLM) y el parámetro de dispersión $\hat{\phi}$

$$r_{spi} = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi} \mathbb{V}(\hat{\mu}_i) (1 - h_{ii})}}$$

- **Residuos de devianza.** Los otros residuos de este modelo, son conocidos como los *residuos de devianza*, porque se desprenden de la devianza de este modelo. En concreto, se define el residuo de devianza, como

- **Residuos de devianza.** Los otros residuos de este modelo, son conocidos como los *residuos de devianza*, porque se desprenden de la devianza de este modelo. En concreto, se define el residuo de devianza, como

- $$d_i = \text{signo}(y_i - n_i \hat{\pi}_i) \left\{ 2 \left[y_i \log \left(\frac{y_i}{n_i \hat{\pi}_i} \right) (n_i - y_i) \log \left(\frac{n_i - y_i}{n_i - n_i \hat{\pi}_i} \right) \right] \right\}^{1/2}$$

- **Residuos de devianza.** Los otros residuos de este modelo, son conocidos como los *residuos de devianza*, porque se desprenden de la devianza de este modelo. En concreto, se define el residuo de devianza, como

- $$d_i = \text{signo}(y_i - n_i \hat{\pi}_i) \left\{ 2 \left[y_i \log \left(\frac{y_i}{n_i \hat{\pi}_i} \right) (n_i - y_i) \log \left(\frac{n_i - y_i}{n_i - n_i \hat{\pi}_i} \right) \right] \right\}^{1/2}$$

- La suma del cuadrado de los residuos de Pearson, proporciona una prueba de bondad de ajuste denominada $\chi^2 = \sum_i r_{p_i}^2$. La suma del cuadrado de los residuos de devianza, $D^2 = \sum_i d_i^2$, proporciona una prueba de bondad de ajuste similar