

- **Machine Learning en Seguros**

- Machine Learning en Seguros
- Módulo IV Tema 1

- **Machine Learning en Seguros**
- **Módulo IV Tema 1**
- **Modelos Lineales Generalizados (GLM)**

- **Machine Learning en Seguros**
- **Módulo IV Tema 1**
- **Modelos Lineales Generalizados (GLM)**
- **GLM: Tweedie model.** El GLM Tweedie es un modelo estadístico perteneciente a la familia de dispersión exponencial, que utiliza una relación varianza-potencia para modelar datos con una gran masa de probabilidad para el valor *cero*, y valores positivos con fuerte sesgo a la derecha

- **Machine Learning en Seguros**
- **Módulo IV Tema 1**
- **Modelos Lineales Generalizados (GLM)**
- **GLM: Tweedie model.** El GLM Tweedie es un modelo estadístico perteneciente a la familia de dispersión exponencial, que utiliza una relación varianza-potencia para modelar datos con una gran masa de probabilidad para el valor *cero*, y valores positivos con fuerte sesgo a la derecha
- El modelo se extiende a *DGLM* mediante la incorporación de un esquema de regresión dual que estima tanto la media como la dispersión, permitiendo así una variabilidad dependiente de las covariables

- **Machine Learning en Seguros**
- **Módulo IV Tema 1**
- **Modelos Lineales Generalizados (GLM)**
- **GLM: Tweedie model.** El GLM Tweedie es un modelo estadístico perteneciente a la familia de dispersión exponencial, que utiliza una relación varianza-potencia para modelar datos con una gran masa de probabilidad para el valor *cero*, y valores positivos con fuerte sesgo a la derecha
- El modelo se extiende a *DGLM* mediante la incorporación de un esquema de regresión dual que estima tanto la media como la dispersión, permitiendo así una variabilidad dependiente de las covariables
- Los avances recientes se centran en integrar *regularización*, *efectos espaciales* y *métodos bayesianos* para mejorar el rendimiento del modelo en campos como los seguros y las ciencias ambientales

- Tweedie models

- **Tweedie models**
- Dentro de los modelos de dispersión exponencial, nos interesa especialmente una clase de distribuciones con funciones de varianza de la forma

- **Tweedie models**

- Dentro de los modelos de dispersión exponencial, nos interesa especialmente una clase de distribuciones con funciones de varianza de la forma

- $\mathbb{V}(\mu) = \mu^p$

- **Tweedie models**

- Dentro de los modelos de dispersión exponencial, nos interesa especialmente una clase de distribuciones con funciones de varianza de la forma

- $\mathbb{V}(\mu) = \mu^p$

- Para algún p . Siguiendo a Jørgensen (1997), estos modelos de dispersión exponencial (EDM) se denominan *modelos Tweedie* en honor a Maurice C. K. Tweedie, estadístico y físico médico británico que presentó el primer estudio exhaustivo sobre ellos en 1984

- **Tweedie models**

- Dentro de los modelos de dispersión exponencial, nos interesa especialmente una clase de distribuciones con funciones de varianza de la forma

- $\mathbb{V}(\mu) = \mu^p$

- Para algún p . Siguiendo a Jørgensen (1997), estos modelos de dispersión exponencial (EDM) se denominan *modelos Tweedie* en honor a Maurice C. K. Tweedie, estadístico y físico médico británico que presentó el primer estudio exhaustivo sobre ellos en 1984
- Los modelos Tweedie se han utilizado en diversos campos, incluidos estudios actuariales, análisis de supervivencia, ecología y meteorología, entre otros

- **Tweedie models**

- Dentro de los modelos de dispersión exponencial, nos interesa especialmente una clase de distribuciones con funciones de varianza de la forma

- $\mathbb{V}(\mu) = \mu^p$

- Para algún p . Siguiendo a Jørgensen (1997), estos modelos de dispersión exponencial (EDM) se denominan *modelos Tweedie* en honor a Maurice C. K. Tweedie, estadístico y físico médico británico que presentó el primer estudio exhaustivo sobre ellos en 1984
- Los modelos Tweedie se han utilizado en diversos campos, incluidos estudios actuariales, análisis de supervivencia, ecología y meteorología, entre otros
- La clase de modelos Tweedie incluye distribuciones discretas, continuas y mixtas. El valor del parámetro del índice de la potencia, p , determina la distribución

- Las distribuciones normal ($p = 0$), Poisson ($p = 1 ; \phi = 1$), gamma ($p = 2$) y gaussiana inversa ($p = 3$) son casos especiales. Aunque las otras distribuciones son menos conocidas, Jørgensen demostró que los modelos Tweedie existen para todos los valores de p fuera del intervalo $(0, 1)$

- Las distribuciones normal ($p = 0$), Poisson ($p = 1$; $\phi = 1$), gamma ($p = 2$) y gaussiana inversa ($p = 3$) son casos especiales. Aunque las otras distribuciones son menos conocidas, Jørgensen demostró que los modelos Tweedie existen para todos los valores de p fuera del intervalo $(0, 1)$
- Los modelos Tweedie con $1 < p < 2$ son mezclas de distribuciones *Poisson-gamma*. Estas distribuciones, denominadas distribuciones *Poisson compuestas*, son distribuciones mixtas definidas sobre los números reales no negativos, con una probabilidad positiva de tomar el valor cero

- Las distribuciones normal ($p = 0$), Poisson ($p = 1 ; \phi = 1$), gamma ($p = 2$) y gaussiana inversa ($p = 3$) son casos especiales. Aunque las otras distribuciones son menos conocidas, Jørgensen demostró que los modelos Tweedie existen para todos los valores de p fuera del intervalo $(0, 1)$
- Los modelos Tweedie con $1 < p < 2$ son mezclas de distribuciones *Poisson-gamma*. Estas distribuciones, denominadas distribuciones *Poisson compuestas*, son distribuciones mixtas definidas sobre los números reales no negativos, con una probabilidad positiva de tomar el valor cero
- La presencia de una masa discreta en cero hace que estas distribuciones sean adecuadas para muchas aplicaciones en las que varias observaciones suelen ser nulas, mientras otras son positivas. En el ámbito de los *seguros no vida*, pueden aplicarse tanto a la tarificación como a la constitución de reservas para siniestros. También se les conoce como distribuciones *gamma compuestas* o *Poisson-gamma*

- Para $p > 2$, las distribuciones son continuas con soporte en los números reales positivos y tienen una forma similar a la distribución gamma pero más asimétricas. Junto con la distribución gamma, a menudo se sugieren como distribuciones para la severidad de los siniestros. Los valores negativos de p dan distribuciones continuas en todo el eje real, pero aún no se ha propuesto ninguna aplicación en seguros

- Para $p > 2$, las distribuciones son continuas con soporte en los números reales positivos y tienen una forma similar a la distribución gamma pero más asimétricas. Junto con la distribución gamma, a menudo se sugieren como distribuciones para la severidad de los siniestros. Los valores negativos de p dan distribuciones continuas en todo el eje real, pero aún no se ha propuesto ninguna aplicación en seguros
- De acuerdo a Dunn y Smyth (2005), aparte de los cuatro casos especiales, ninguno de los modelos Tweedie tiene funciones de densidad que puedan expresarse en forma cerrada. Las densidades de Tweedie pueden expresarse, en forma general, para $p \neq 1, 2$, como

- Para $p > 2$, las distribuciones son continuas con soporte en los números reales positivos y tienen una forma similar a la distribución gamma pero más asimétricas. Junto con la distribución gamma, a menudo se sugieren como distribuciones para la severidad de los siniestros. Los valores negativos de p dan distribuciones continuas en todo el eje real, pero aún no se ha propuesto ninguna aplicación en seguros
- De acuerdo a Dunn y Smyth (2005), aparte de los cuatro casos especiales, ninguno de los modelos Tweedie tiene funciones de densidad que puedan expresarse en forma cerrada. Las densidades de Tweedie pueden expresarse, en forma general, para $p \neq 1, 2$, como

- $$f_Y(y; \mu, \phi/w, p) = a(y; \phi/w, p) \exp \left\{ \frac{w}{\phi} \left(y \frac{\mu^{1-p}}{1-p} - \frac{\mu^{2-p}}{2-p} \right) \right\}$$

- Para $p > 2$, las distribuciones son continuas con soporte en los números reales positivos y tienen una forma similar a la distribución gamma pero más asimétricas. Junto con la distribución gamma, a menudo se sugieren como distribuciones para la severidad de los siniestros. Los valores negativos de p dan distribuciones continuas en todo el eje real, pero aún no se ha propuesto ninguna aplicación en seguros
- De acuerdo a Dunn y Smyth (2005), aparte de los cuatro casos especiales, ninguno de los modelos Tweedie tiene funciones de densidad que puedan expresarse en forma cerrada. Las densidades de Tweedie pueden expresarse, en forma general, para $p \neq 1, 2$, como
- $$f_Y(y; \mu, \phi/w, p) = a(y; \phi/w, p) \exp \left\{ \frac{w}{\phi} \left(y \frac{\mu^{1-p}}{1-p} - \frac{\mu^{2-p}}{2-p} \right) \right\}$$
- La función $a(y; \phi/w, p)$ debe evaluarse numéricamente. Dunn y Smyth (2001) proponen métodos numéricos para su cálculo

- Tweedie: GLM

- **Tweedie: GLM**

- Los modelos de regresión Tweedie, son un tipo especial de modelos lineales generalizados (GLM) útiles cuando se desea modelar una variable de respuesta que toma el valor *cero*, pero que por lo demás es positiva y continua

- **Tweedie: GLM**

- Los modelos de regresión Tweedie, son un tipo especial de modelos lineales generalizados (GLM) útiles cuando se desea modelar una variable de respuesta que toma el valor *cero*, pero que por lo demás es positiva y continua
- Algunos ejemplos incluyen los datos de precipitación pluvial diaria, que, dado que ocurren días sin lluvia, puede tener muchos registros en cero; número de reclamaciones en la cobertura de algún seguro, donde es común que muchas pólizas no realicen reclamaciones y se tenga una frecuencia importante en este valor, y varios ejemplos más

- **Tweedie: GLM**

- Los modelos de regresión Tweedie, son un tipo especial de modelos lineales generalizados (GLM) útiles cuando se desea modelar una variable de respuesta que toma el valor *cero*, pero que por lo demás es positiva y continua
- Algunos ejemplos incluyen los datos de precipitación pluvial diaria, que, dado que ocurren días sin lluvia, puede tener muchos registros en cero; número de reclamaciones en la cobertura de algún seguro, donde es común que muchas pólizas no realicen reclamaciones y se tenga una frecuencia importante en este valor, y varios ejemplos más
- Este tipo de datos puede presentar ceros, a menudo en gran cantidad, además de valores positivos. Al modelar datos de esta naturaleza, es importante garantizar que el modelo no prediga valores negativos. Asimismo, es posible que queramos aplicar una transformación logarítmica a los datos sin tener que descartar los ceros; los modelos Tweedie permiten ambas cosas

- Ampliamente utilizados en ciencias actuariales, estadística espacial y otros campos que manejan *datos de respuesta semicontínuos o mixtos*, los GLM Tweedie cobran especial relevancia cuando los datos presentan tanto ceros como valores positivos con sesgo a la derecha, tal como ocurre en las distribuciones Poisson-gamma compuestas

- Ampliamente utilizados en ciencias actuariales, estadística espacial y otros campos que manejan *datos de respuesta semicontínuos o mixtos*, los GLM Tweedie cobran especial relevancia cuando los datos presentan tanto ceros como valores positivos con sesgo a la derecha, tal como ocurre en las distribuciones Poisson-gamma compuestas
- **Estrategias de modelación para datos de seguros**

- Ampliamente utilizados en ciencias actuariales, estadística espacial y otros campos que manejan *datos de respuesta semicontínuos o mixtos*, los GLM Tweedie cobran especial relevancia cuando los datos presentan tanto ceros como valores positivos con sesgo a la derecha, tal como ocurre en las distribuciones Poisson-gamma compuestas
- **Estrategias de modelación para datos de seguros**
- En datos generados por pago de reclamaciones de una cobertura de seguros, se presentan dos tipos de variables de interés: La frecuencia con que ocurren las reclamaciones (una variable discreta de conteo) y la severidad (montos de reclamación, una variable continua regularmente con sesgo fuerte a la derecha) de cada una de estas reclamaciones. Entonces, se pueden adoptar dos estrategias para modelar este tipo de datos, con el objetivo final de calcular la *prima neta* que debe pagar cada asegurado (Tarificación)

- La primera estrategia consiste en modelar por separado la frecuencia de reclamaciones (N) y, por otro lado, la severidad de las mismas (Y). Para, posteriormente, calcular la prima como

- La primera estrategia consiste en modelar por separado la frecuencia de reclamaciones (N) y, por otro lado, la severidad de las mismas (Y). Para, posteriormente, calcular la prima como

$$\bullet \mathbb{P}(\mathbf{X}) = \mathbb{E}(Y|\mathbf{X})\mathbb{E}(N|\mathbf{X})$$

- La primera estrategia consiste en modelar por separado la frecuencia de reclamaciones (N) y, por otro lado, la severidad de las mismas (Y). Para, posteriormente, calcular la prima como

$$\bullet \mathbb{P}(\mathbf{X}) = \mathbb{E}(Y|\mathbf{X})\mathbb{E}(N|\mathbf{X})$$

- Donde $\mathbf{X}$ es la matriz de covariables o de variables predictoras de cada sujeto. Este enfoque de modelado implica que los dos modelos para estas variables, realmente las ajustan.

- La primera estrategia consiste en modelar por separado la frecuencia de reclamaciones (N) y, por otro lado, la severidad de las mismas (Y). Para, posteriormente, calcular la prima como

$$\bullet \mathbb{P}(\mathbf{X}) = \mathbb{E}(Y|\mathbf{X})\mathbb{E}(N|\mathbf{X})$$

- Donde $\mathbf{X}$ es la matriz de covariables o de variables predictoras de cada sujeto. Este enfoque de modelado implica que los dos modelos para estas variables, realmente las ajustan.
- Para modelar N , se recurren a modelos como regresión Poisson (GLM), o regresión Binomial negativa

- La primera estrategia consiste en modelar por separado la frecuencia de reclamaciones (N) y, por otro lado, la severidad de las mismas (Y). Para, posteriormente, calcular la prima como

$$\bullet \mathbb{P}(\mathbf{X}) = \mathbb{E}(Y|\mathbf{X})\mathbb{E}(N|\mathbf{X})$$

- Donde $\mathbf{X}$ es la matriz de covariables o de variables predictoras de cada sujeto. Este enfoque de modelado implica que los dos modelos para estas variables, realmente las ajustan.
- Para modelar N , se recurren a modelos como regresión Poisson (GLM), o regresión Binomial negativa
- En el caso de Y , dado que es una variable positiva y sesgada a la derecha, los GLM que pueden ajustarla son el de regresión Gamma (GLM) y el de regresión Gaussiana Inversa (GLM)

- La primera estrategia consiste en modelar por separado la frecuencia de reclamaciones (N) y, por otro lado, la severidad de las mismas (Y). Para, posteriormente, calcular la prima como

$$\bullet \mathbb{P}(\mathbf{X}) = \mathbb{E}(Y|\mathbf{X})\mathbb{E}(N|\mathbf{X})$$

- Donde $\mathbf{X}$ es la matriz de covariables o de variables predictoras de cada sujeto. Este enfoque de modelado implica que los dos modelos para estas variables, realmente las ajustan.
- Para modelar N , se recurren a modelos como regresión Poisson (GLM), o regresión Binomial negativa
- En el caso de Y , dado que es una variable positiva y sesgada a la derecha, los GLM que pueden ajustarla son el de regresión Gamma (GLM) y el de regresión Gaussiana Inversa (GLM)
- La misma observación que se hizo para los modelos de frecuencia, aplica en estos modelos para la severidad: Deben ajustar bien a los datos

- La segunda estrategia es modelar directamente la severidad a través de un modelo Tweedie. Recordemos que si el parámetro p de este modelo, se encuentra en el intervalo $1 < p < 2$, entonces este modelo Tweedie se corresponde con el modelo Poisson-Gamma compuesto

- La segunda estrategia es modelar directamente la severidad a través de un modelo Tweedie. Recordemos que si el parámetro p de este modelo, se encuentra en el intervalo $1 < p < 2$, entonces este modelo Tweedie se corresponde con el modelo Poisson-Gamma compuesto
- **¿Regresión Tweedie o regresiones Poisson-Gamma?**

- La segunda estrategia es modelar directamente la severidad a través de un modelo Tweedie. Recordemos que si el parámetro p de este modelo, se encuentra en el intervalo $1 < p < 2$, entonces este modelo Tweedie se corresponde con el modelo Poisson-Gamma compuesto
- **¿Regresión Tweedie o regresiones Poisson-Gamma?**
- La pregunta es: ¿es lo mismo utilizar una regresión Tweedie que dos regresiones (Poisson y Gamma)?

- La segunda estrategia es modelar directamente la severidad a través de un modelo Tweedie. Recordemos que si el parámetro p de este modelo, se encuentra en el intervalo $1 < p < 2$, entonces este modelo Tweedie se corresponde con el modelo Poisson-Gamma compuesto
- **¿Regresión Tweedie o regresiones Poisson-Gamma?**
- La pregunta es: ¿es lo mismo utilizar una regresión Tweedie que dos regresiones (Poisson y Gamma)?
- En términos de distribuciones, ambas opciones son equivalentes; sin embargo, cuando existe heterogeneidad y variables explicativas, podría resultar mucho más interesante aprovechar toda la información disponible y realizar dos regresiones

- La segunda estrategia es modelar directamente la severidad a través de un modelo Tweedie. Recordemos que si el parámetro p de este modelo, se encuentra en el intervalo $1 < p < 2$, entonces este modelo Tweedie se corresponde con el modelo Poisson-Gamma compuesto
- **¿Regresión Tweedie o regresiones Poisson-Gamma?**
- La pregunta es: ¿es lo mismo utilizar una regresión Tweedie que dos regresiones (Poisson y Gamma)?
- En términos de distribuciones, ambas opciones son equivalentes; sin embargo, cuando existe heterogeneidad y variables explicativas, podría resultar mucho más interesante aprovechar toda la información disponible y realizar dos regresiones
- **Caso homogéneo (sin covariables).** En el caso homogéneo, sin ninguna variable explicativa, la distribución Tweedie y la distribución compuesta Poisson-gamma constituyen representaciones equivalentes (es decir, se trata simplemente de una reparametrización)

- **Caso heterogéneo (con covariables)**. En este caso, es posible que la frecuencia y la severidad pueden explicarse mediante características diferentes, que implica usar más información en esta modelación, y constituye una motivación para considerar dos modelos

- **Caso heterogéneo (con covariables)**. En este caso, es posible que la frecuencia y la severidad pueden explicarse mediante características diferentes, que implica usar más información en esta modelación, y constituye una motivación para considerar dos modelos
- **Extensiones: modelos Tweedie cero inflados y estimación no paramétrica**

- **Caso heterogéneo (con covariables)**. En este caso, es posible que la frecuencia y la severidad pueden explicarse mediante características diferentes, que implica usar más información en esta modelación, y constituye una motivación para considerar dos modelos
- **Extensiones: modelos Tweedie cero inflados y estimación no paramétrica**
- Un modelo *Tweedie cero inflado* amplía el modelo estándar Tweedie al introducir masa de probabilidad adicional en el valor cero, abordando así datos no negativos extremadamente desequilibrados que se caracterizan tanto por una fuerte asimetría positiva como por una elevada proporción de ceros

- **Caso heterogéneo (con covariables)**. En este caso, es posible que la frecuencia y la severidad pueden explicarse mediante características diferentes, que implica usar más información en esta modelación, y constituye una motivación para considerar dos modelos
- **Extensiones: modelos Tweedie cero inflados y estimación no paramétrica**
- Un modelo *Tweedie cero inflado* amplía el modelo estándar Tweedie al introducir masa de probabilidad adicional en el valor cero, abordando así datos no negativos extremadamente desequilibrados que se caracterizan tanto por una fuerte asimetría positiva como por una elevada proporción de ceros
- Esto contrasta con los modelos de mezcla que incluyen un parámetro explícito de inflación por ceros y con las variantes jerárquicas compuestas (e.g., Poisson-Tweedie o PET (Poisson Exponential Tweedie)), en las que la inflación por ceros surge de manera intrínseca a partir de mecanismos de mezcla o composición

- Los avances empíricos recientes se basan en técnicas de *boosting* y aprendizaje profundo (*deep learning*) para la regresión no paramétrica y la parametrización flexible de todos los componentes del modelo, lo que permite su aplicación práctica en grandes conjuntos de datos y desbalanceados en el sentido expuesto anteriormente

- Los avances empíricos recientes se basan en técnicas de *boosting* y aprendizaje profundo (*deep learning*) para la regresión no paramétrica y la parametrización flexible de todos los componentes del modelo, lo que permite su aplicación práctica en grandes conjuntos de datos y desbalanceados en el sentido expuesto anteriormente
- Los parámetros, tanto en los modelos estándar como en los cero inflados, pueden estimarse mediante *algoritmos EM generalizados*, permitiendo que la media, la dispersión y las probabilidades dependan de covariables ajustadas mediante *gradient-boosted trees*

- Los avances empíricos recientes se basan en técnicas de *boosting* y aprendizaje profundo (*deep learning*) para la regresión no paramétrica y la parametrización flexible de todos los componentes del modelo, lo que permite su aplicación práctica en grandes conjuntos de datos y desbalanceados en el sentido expuesto anteriormente
- Los parámetros, tanto en los modelos estándar como en los cero inflados, pueden estimarse mediante *algoritmos EM generalizados*, permitiendo que la media, la dispersión y las probabilidades dependan de covariables ajustadas mediante *gradient-boosted trees*
- Los modelos Tweedie y Tweedie cero inflados, superan a los modelos donde se ajuste por separado (dos partes) la frecuencia y la severidad, y a los binomiales negativos, en cuanto al manejo simultáneo de una inflación de ceros extrema y colas derechas pesadas

- En datos de reclamaciones de seguros con una gran cantidad de ceros (fuertemente inflados en cero. Más del 90 % de ceros), los métodos auxiliados por *boosting* (p. ej., EMTboost, ZITboost, CatBoost ZITwBT2) arrojan una desviación absoluta media (MAD) sustancialmente menor y coeficientes de Gini, para datos que no se usaron en el ajuste del modelo, más elevados en comparación con los enfoques de *boosting Tweedie puro* o *Tobit* con inflación de ceros

- En datos de reclamaciones de seguros con una gran cantidad de ceros (fuertemente inflados en cero. Más del 90 % de ceros), los métodos auxiliados por *boosting* (p. ej., EMTboost, ZITboost, CatBoost ZITwBT2) arrojan una desviación absoluta media (MAD) sustancialmente menor y coeficientes de Gini, para datos que no se usaron en el ajuste del modelo, más elevados en comparación con los enfoques de *boosting Tweedie puro* o *Tobit* con inflación de ceros
- Las relaciones empíricas media-varianza y los gráficos Q-Q validan cuantitativamente la presencia de colas pesadas y frecuencias de ceros, más realistas en diversos contextos (seguros, gastos médicos, datos de conteo)

- Consideraciones finales

- **Consideraciones finales**

- Los datos de reclamaciones de seguros presentan una estructura peculiar: la mayoría de los asegurados no presenta ninguna reclamación, por lo que el importe total es exactamente cero, mientras que el resto genera una distribución continua de montos positivos con un fuerte sesgo hacia la derecha

● Consideraciones finales

- Los datos de reclamaciones de seguros presentan una estructura peculiar: la mayoría de los asegurados no presenta ninguna reclamación, por lo que el importe total es exactamente cero, mientras que el resto genera una distribución continua de montos positivos con un fuerte sesgo hacia la derecha
- Esta estructura semicontinua invalida los métodos de regresión convencionales. Existen dos enfoques de modelación para resolver esta situación: el modelo lineal generalizado (GLM) Tweedie-Poisson compuesto, que modela toda la distribución en un único ajuste, y el modelo de dos partes: de frecuencia y severidad, que desglosa el problema en dos vertientes: *si se produce una reclamación* (frecuencia) y *cuál es su monto* (severidad)

● Consideraciones finales

- Los datos de reclamaciones de seguros presentan una estructura peculiar: la mayoría de los asegurados no presenta ninguna reclamación, por lo que el importe total es exactamente cero, mientras que el resto genera una distribución continua de montos positivos con un fuerte sesgo hacia la derecha
- Esta estructura semicontinua invalida los métodos de regresión convencionales. Existen dos enfoques de modelación para resolver esta situación: el modelo lineal generalizado (GLM) Tweedie-Poisson compuesto, que modela toda la distribución en un único ajuste, y el modelo de dos partes: de frecuencia y severidad, que desglosa el problema en dos vertientes: *si se produce una reclamación* (frecuencia) y *cuál es su monto* (severidad)
- La elección entre ambos enfoques no es meramente una cuestión de preferencia técnica

- El modelo Tweedie ofrece un enfoque de prima pura única fácil de implementar, mientras que el modelo de dos partes revela la razón por la cual algún segmento de la cobertura resulta costoso: ¿se debe a una mayor frecuencia de reclamaciones o a reclamaciones de mayor monto? Esta distinción es fundamental para tarifas actuariales, y debería serlo también para cualquiera que modele costos, gastos en salud o cualquier variable que presente una concentración significativa de valores en cero

- El modelo Tweedie ofrece un enfoque de prima pura única fácil de implementar, mientras que el modelo de dos partes revela la razón por la cual algún segmento de la cobertura resulta costoso: ¿se debe a una mayor frecuencia de reclamaciones o a reclamaciones de mayor monto? Esta distinción es fundamental para tarifas actuariales, y debería serlo también para cualquiera que modele costos, gastos en salud o cualquier variable que presente una concentración significativa de valores en cero
- **Resultado fundamental.** Ambos modelos proporcionan un monto total esperado (la prima pura) muy similar, pero lo descomponen de manera diferente. *El modelo Tweedie integra la frecuencia y la severidad en una única función de varianza*, mientras que el modelo de dos partes las mantiene como regresiones separadas (frecuencia y severidad) e interpretables individualmente

- El problema de la condición semicontinua del costo de siniestros

- **El problema de la condición semicontinua del costo de siniestros**
- El costo total de los siniestros de una póliza, es la suma de un número aleatorio de siniestros individuales (modelo agregado)

- **El problema de la condición semicontinua del costo de siniestros**
- El costo total de los siniestros de una póliza, es la suma de un número aleatorio de siniestros individuales (modelo agregado)
- El número de siniestros sigue una distribución de conteo y el monto de cada siniestro es una cantidad positiva con distribución sesgada a la derecha

- **El problema de la condición semicontinua del costo de siniestros**
- El costo total de los siniestros de una póliza, es la suma de un número aleatorio de siniestros individuales (modelo agregado)
- El número de siniestros sigue una distribución de conteo y el monto de cada siniestro es una cantidad positiva con distribución sesgada a la derecha
- El resultado es una distribución con una masa de probabilidad en cero (ausencia de siniestros) y una parte continua (montos de siniestros)

- **El problema de la condición semicontinua del costo de siniestros**
- El costo total de los siniestros de una póliza, es la suma de un número aleatorio de siniestros individuales (modelo agregado)
- El número de siniestros sigue una distribución de conteo y el monto de cada siniestro es una cantidad positiva con distribución sesgada a la derecha
- El resultado es una distribución con una masa de probabilidad en cero (ausencia de siniestros) y una parte continua (montos de siniestros)
- En este caso, un modelo lineal generalizado (GLM) de tipo Gamma no funciona, ya que la distribución Gamma no está definida en cero

- El modelo GLM Tweedie-Poisson compuesto

- **El modelo GLM Tweedie-Poisson compuesto**
- La familia Tweedie es una clase de modelos de dispersión exponencial cuya varianza es una potencia de la media

- **El modelo GLM Tweedie-Poisson compuesto**
- La familia Tweedie es una clase de modelos de dispersión exponencial cuya varianza es una potencia de la media

- $$\mathbb{V}(Y) = \phi\mu^p$$

- **El modelo GLM Tweedie-Poisson compuesto**
- La familia Tweedie es una clase de modelos de dispersión exponencial cuya varianza es una potencia de la media

$$\bullet \mathbb{V}(Y) = \phi\mu^p$$

- Cuando el parámetro de potencia p está entre 1 y 2 ($p \in (1, 2)$), la distribución *Tweedie* es exactamente la *distribución compuesta Poisson-Gamma*: número de reclamaciones Poisson cuyas severidades siguen una distribución Gamma

- **El modelo GLM Tweedie-Poisson compuesto**

- La familia Tweedie es una clase de modelos de dispersión exponencial cuya varianza es una potencia de la media

$$\bullet \mathbb{V}(Y) = \phi \mu^p$$

- Cuando el parámetro de potencia p está entre 1 y 2 ($p \in (1, 2)$), la distribución *Tweedie* es exactamente la *distribución compuesta Poisson-Gamma*: número de reclamaciones Poisson cuyas severidades siguen una distribución Gamma
- Esa es precisamente la estructura del monto agregado de las reclamaciones; por ello, *un único GLM Tweedie con función de enlace logarítmica* puede modelar toda la respuesta semicontinua, incluyendo los ceros. La media se modela de la siguiente manera:

- **El modelo GLM Tweedie-Poisson compuesto**

- La familia Tweedie es una clase de modelos de dispersión exponencial cuya varianza es una potencia de la media

$$\bullet \mathbb{V}(Y) = \phi\mu^p$$

- Cuando el parámetro de potencia p está entre 1 y 2 ($p \in (1, 2)$), la distribución *Tweedie* es exactamente la *distribución compuesta Poisson-Gamma*: número de reclamaciones Poisson cuyas severidades siguen una distribución Gamma
- Esa es precisamente la estructura del monto agregado de las reclamaciones; por ello, *un único GLM Tweedie con función de enlace logarítmica* puede modelar toda la respuesta semicontinua, incluyendo los ceros. La media se modela de la siguiente manera:

$$\bullet \log\mu_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik}$$

- El parámetro p se estima mediante el método de verosimilitud perfil en lugar de asignarle un valor arbitrario

- El parámetro p se estima mediante el método de verosimilitud perfil en lugar de asignarle un valor arbitrario
- **El modelo de dos partes: frecuencia y severidad**

- El parámetro p se estima mediante el método de verosimilitud perfil en lugar de asignarle un valor arbitrario
- **El modelo de dos partes: frecuencia y severidad**
- El modelo de dos partes desglosa el monto esperado en dos componentes estimados de forma independiente

- El parámetro p se estima mediante el método de verosimilitud perfil en lugar de asignarle un valor arbitrario
- **El modelo de dos partes: frecuencia y severidad**
- El modelo de dos partes desglosa el monto esperado en dos componentes estimados de forma independiente

$$\bullet \mathbb{E}[Monto] = \underbrace{\mathbb{P}(Relamación > 0)}_{\text{Frecuencia, logística}} \times \underbrace{\mathbb{E}[monto|monto > 0]}_{\text{Severidad, Gamma}}$$

- El parámetro p se estima mediante el método de verosimilitud perfil en lugar de asignarle un valor arbitrario
- **El modelo de dos partes: frecuencia y severidad**
- El modelo de dos partes desglosa el monto esperado en dos componentes estimados de forma independiente

$$\bullet \mathbb{E}[Monto] = \underbrace{\mathbb{P}(Relamación > 0)}_{\text{Frecuencia, logística}} \times \underbrace{\mathbb{E}[monto|monto > 0]}_{\text{Severidad, Gamma}}$$

- La primera parte consiste en una regresión logística (o Poisson) para determinar si se produce un siniestro; la segunda es un modelo lineal generalizado (GLM) de distribución Gamma ajustado únicamente a los siniestros con importe positivo. El producto de ambos componentes ajustados proporciona el monto esperado incondicional. Dado que cada parte constituye un GLM independiente, es posible observar cómo cada covariable modifica la probabilidad de siniestro por separado de cómo afecta al monto del mismo

- Paso a paso: Ajuste de ambos modelos en R

- **Paso a paso: Ajuste de ambos modelos en R**

- Inspeccione la frecuencia de probabilidad en cero. Calcule la proporción de pólizas con monto cero. Un pico pronunciado en cero confirma la estructura semicontinua y descarta un modelo Gamma simple

- Paso a paso: Ajuste de ambos modelos en R

- Inspeccione la frecuencia de probabilidad en cero. Calcule la proporción de pólizas con monto cero. Un pico pronunciado en cero confirma la estructura semicontinua y descarta un modelo Gamma simple
- Estime el parámetro de potencia Tweedie. Utilice *tweedie.profile()* del paquete *tweedie* para determinar el valor de $p \in (1, 2)$ mediante el método de verosimilitud perfil

● Paso a paso: Ajuste de ambos modelos en R

- Inspeccione la frecuencia de probabilidad en cero. Calcule la proporción de pólizas con monto cero. Un pico pronunciado en cero confirma la estructura semicontinua y descarta un modelo Gamma simple
- Estime el parámetro de potencia Tweedie. Utilice `tweedie.profile()` del paquete `tweedie` para determinar el valor de $p \in (1, 2)$ mediante el método de verosimilitud perfil
- Ajuste el GLM Tweedie. Llame a `glm()` con `family = tweedie(var.power = p, link.power = 0)` (del paquete `statmod`) para obtener un modelo único con función liga logarítmica

● Paso a paso: Ajuste de ambos modelos en R

- Inspeccione la frecuencia de probabilidad en cero. Calcule la proporción de pólizas con monto cero. Un pico pronunciado en cero confirma la estructura semicontinua y descarta un modelo Gamma simple
- Estime el parámetro de potencia Tweedie. Utilice `tweedie.profile()` del paquete `tweedie` para determinar el valor de $p \in (1, 2)$ mediante el método de verosimilitud perfil
- Ajuste el GLM Tweedie. Llame a `glm()` con `family = tweedie(var.power = p, link.power = 0)` (del paquete `statmod`) para obtener un modelo único con función liga logarítmica
- Ajuste el componente de frecuencia. Utilice un GLM logístico sobre el indicador de número de siniestros

● Paso a paso: Ajuste de ambos modelos en R

- Inspeccione la frecuencia de probabilidad en cero. Calcule la proporción de pólizas con monto cero. Un pico pronunciado en cero confirma la estructura semicontinua y descarta un modelo Gamma simple
- Estime el parámetro de potencia Tweedie. Utilice `tweedie.profile()` del paquete `tweedie` para determinar el valor de $p \in (1, 2)$ mediante el método de verosimilitud perfil
- Ajuste el GLM Tweedie. Llame a `glm()` con `family = tweedie(var.power = p, link.power = 0)` (del paquete `statmod`) para obtener un modelo único con función liga logarítmica
- Ajuste el componente de frecuencia. Utilice un GLM logístico sobre el indicador de número de siniestros
- Ajuste el componente de severidad. Utilice un GLM Gamma con enlace logarítmico aplicado únicamente a los siniestros con monto positivo

● Paso a paso: Ajuste de ambos modelos en R

- Inspeccione la frecuencia de probabilidad en cero. Calcule la proporción de pólizas con monto cero. Un pico pronunciado en cero confirma la estructura semicontinua y descarta un modelo Gamma simple
- Estime el parámetro de potencia Tweedie. Utilice `tweedie.profile()` del paquete *tweedie* para determinar el valor de $p \in (1, 2)$ mediante el método de verosimilitud perfil
- Ajuste el GLM Tweedie. Llame a `glm()` con `family = tweedie(var.power = p, link.power = 0)` (del paquete *statmod*) para obtener un modelo único con función liga logarítmica
- Ajuste el componente de frecuencia. Utilice un GLM logístico sobre el indicador de número de siniestros
- Ajuste el componente de severidad. Utilice un GLM Gamma con enlace logarítmico aplicado únicamente a los siniestros con monto positivo
- Multiplique la frecuencia por la severidad y compare el costo medio predicho por ambos modelos con el costo observado a lo largo de los deciles de riesgo

● Tweedie frente a modelos de dos partes: Comparación

Aspecto	Tweedie (Poisson compuesto)	Dos partes (frecuencia-severidad)
Número de ajustes	Un GLM	Dos GLMs (logístico + Gamma)
Manejo de ceros	Masa observada en cero	A través del modelo de frecuencia
Interpretabilidad	Conjunto único de coeficientes para el monto total	Efectos separados de frecuencia y severidad
Parámetro adicional	Parámetro de potencia p a estimar	Ninguno
Uso típico	Tarificación de prima pura, simplicidad de implementación	Análisis diagnóstico, transparencia regulatoria