

Machine Learning en Seguros

Módulo IV Tema 1

Modelos Lineales Generalizados (GLM)

Bases de datos

1.- La base de datos *Nor_Auto.csv* comprende 183,999 observaciones de siniestros en pólizas de seguro de automóviles durante un periodo de un año. Las variables que contiene son:

- *Male*: 1 si el asegurado es hombre, 0 en caso contrario
- *Young*: 1 si el asegurado tiene menos de 26 años, 0 en caso contrario
- *DistLimit*: El límite de distancia establecido en el contrato de seguro: "8000 km", "12000 km", "16000 km", "20000 km", "25000-30000 km", "no limit" (sin límite)
- *GeoRegion*: Densidad de la región geográfica (de mayor a menor): "High+", "High-", "Medium+", "Medium-", "Low+", "Low-"
- *Expo*: Exposición expresada como fracción de año

- ClaimAmount: 0 o el importe medio del siniestro si $NbClaim > 0$
- NbClaim: El número de siniestros
- Con esta información: Construya un modelo para la prima pura de riesgo ajustando un modelo para la frecuencia de reclamaciones y otro para la severidad de las mismas
- Evalúe la bondad de ajuste de su modelo
- Construya, si es posible, un modelo Tweedie compuesto para la prima de riesgo. Evalúe la bondad de ajuste de este modelo
- Compare los resultados de ambos modelos

2.- dataOhlsson: Motorcycle Insurance

Descripción: Los datos de este estudio de caso provienen de la antigua compañía de seguros sueca Wasa y se refieren a seguros de daños parciales, en esta ocasión para motocicletas. El conjunto incluye datos agregados sobre todas las pólizas y los siniestros ▶

registrados entre 1994 y 1998; el motivo para utilizar estos datos —relativamente antiguos— es la confidencialidad, ya que no es posible divulgar información más reciente sobre operaciones en curso

La base *Ohlsson.csv* contiene la información sobre este estudio. Es un `data.frame` con 64548 observaciones. Las 9 variables son (Los nombres están en sueco)

- *'agarald'*: Edad del propietario, entre 0 y 99 años (vector numérico)
- *'kon'*: Edad del propietario, entre 0 y 99 años (factor con niveles K y M)
- *'zon'*: Zona geográfica numerada del 1 al 7, según una clasificación estándar de todas las parroquias suecas (vector numérico)
- *'mcklass'*: Clase MC (motocicleta), una clasificación basada en la denominada relación EV, definida como $(\text{potencia del motor en kW} \times 100) / (\text{peso del vehículo en kg} + 75)$,

redondeada al entero inferior más cercano; los 75 kg representan el peso medio del conductor. Las relaciones EV se dividen en siete clases (vector numérico)

- '*fordald*': Antigüedad del vehículo, entre 0 y 99 años (vector numérico)
- '*bonuskl*': Clase de bonificación, con valores del 1 al 7; un conductor nuevo comienza en la clase de bonificación 1 y, por cada año sin siniestros, la clase aumenta en 1; tras el primer siniestro, la bonificación disminuye en 2, y el conductor no puede regresar a la clase 7 sin acumular 6 años consecutivos sin siniestros (vector numérico)
- '*duration*': Número de años de vigencia de la póliza (vector numérico)
- '*antskad*': Número de siniestros (vector numérico)
- '*skadkost*': Coste de los siniestros (vector numérico)

- Con esta información: Construya un modelo para la prima pura de riesgo ajustando un modelo para la frecuencia de reclamaciones y otro para la severidad de las mismas
- Evalúe la bondad de ajuste de su modelo
- Construya, si es posible, un modelo Tweedie compuesto para la prima de riesgo. Evalúe la bondad de ajuste de este modelo
- Compare los resultados de ambos modelos

3.- La base de datos *car.csv* es un conjunto de datos de pólizas de seguro de vehículos con una vigencia de un año, contratadas en 2004 o 2005. Consta de 67,856. Las variable que contiene son

- *veh_value*: vehicle value, in \$10,000s
- *exposure*: 0-1
- *clm*: occurrence of claim (0 = no, 1 = yes)
- *numclaims*: number of claims
- *claimcst0*: claim amount (0 if no claim)

- *veh_body*: vehicle body, coded as BUS CONV T COUPE HBACK HDTOP MCARA MIBUS PANVN RDSTR SEDAN STN WG TRUCK UTE
- *veh_age*: 1 (youngest), 2, 3, 4
- *gender*: a factor with levels F M
- *area*: a factor with levels A B C D E F
- *agecat*: 1 (youngest), 2, 3, 4, 5, 6
- Con esta información: Construya un modelo para la prima pura de riesgo ajustando un modelo para la frecuencia de reclamaciones y otro para la severidad de las mismas
- Evalúe la bondad de ajuste de su modelo
- Construya, si es posible, un modelo Tweedie compuesto para la prima de riesgo. Evalúe la bondad de ajuste de este modelo
- Compare los resultados de ambos modelos